

Principles and Applications of Genetic Algorithms and their Improvements

遗传算法及其改进算法的原理与应用

Yuhong Wang¹, Xiong Gao², Guanyu Wu²

¹ Hanhong College, Southwest University

² College of Electronic Information Engineering, Southwest University

Presented by Yuhong Wang

March 25, 2025 Chongqing

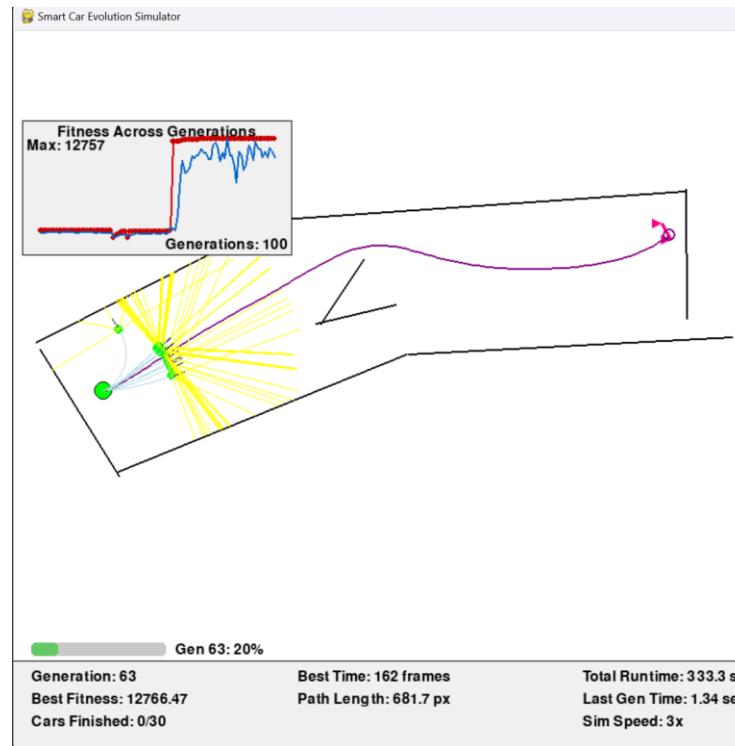
Principles and Applications of Genetic Algorithms and their Improvements

Principles: SGA; DCGA; DPGA; AGA

Applications: Math; Biology; Deep Learning

DEMO

A mini-game based on GA



Generation: 63
Best Fitness: 12766.47
Cars Finished: 0/30

Best Time: 162 frames
Path Length: 681.7 px

Total Runtime: 333.3 sec
Last Gen Time: 1.34 sec
Sim Speed: 3x

Generation: 75
Best Fitness: 12793.25
Cars Finished: 0/30

Best Time: 161 frames
Path Length: 679.4 px

Total Runtime: 347.7 sec
Last Gen Time: 0.99 sec
Sim Speed: 4x

Generation: 103
Best Fitness: 12805.08
Cars Finished: 0/30

Best Time: 160 frames
Path Length: 675.8 px

Total Runtime: 374.6 sec
Last Gen Time: 0.81 sec
Sim Speed: 4x

Background



Genetic Algorithm¹ is a search algorithm for optimization based on Mendel's laws and Darwin's theory ?+(Watson-Crick).

It performs selection(选择) , crossover (遗传) and mutation (变异) operations in the population (种群) by simulating the process of biological evolution (进化) , so as to optimize the objective function (目标函数) step by step (演化) .

¹John H. Holland

**1850s** Population: Darwin's Theory of Evolution¹ -The Doctrine of Natural Selection

过度繁殖、生存竞争、遗传变异、适者生存

e.g. Giraffe Evolution

1900s Genetic Factor : Mendel's Law² -Cross-cutting and selection

等位基因、分离定律、自由组合、控制性状

e.g. Pea test

1950s DNA Structure : Watson-Crick discovered the structure of the DNA³.

基因、染色体

e.g. Double helix structure of DNA

¹Darwin ²Mendel ³James Dewey Watson



Population → Genetic Factor → **Algorithm**

1970s Genetic Algorithms¹ - Heuristic Search Optimization Methods

$$f(x) = g(x) + h(x)$$

$f(x)$ 评估函数，评估节点重要性

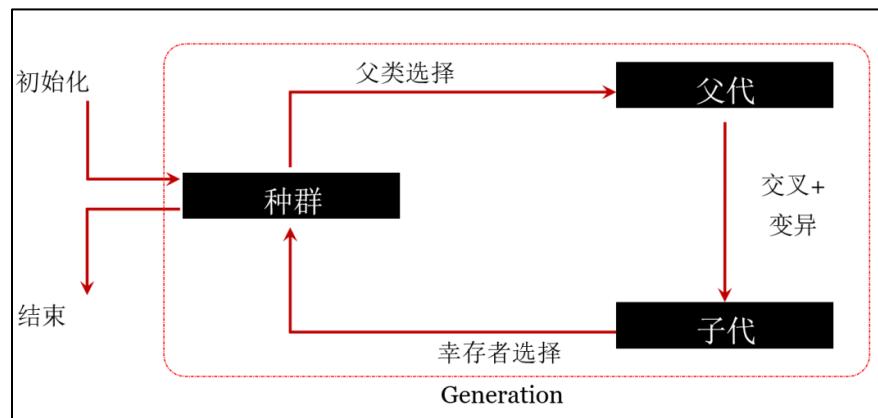
$g(x)$ 实际代价，从 s_0 到 x 的实际代价

$h(x)$ 评估代价，从 x 到 s_0 的评估代价

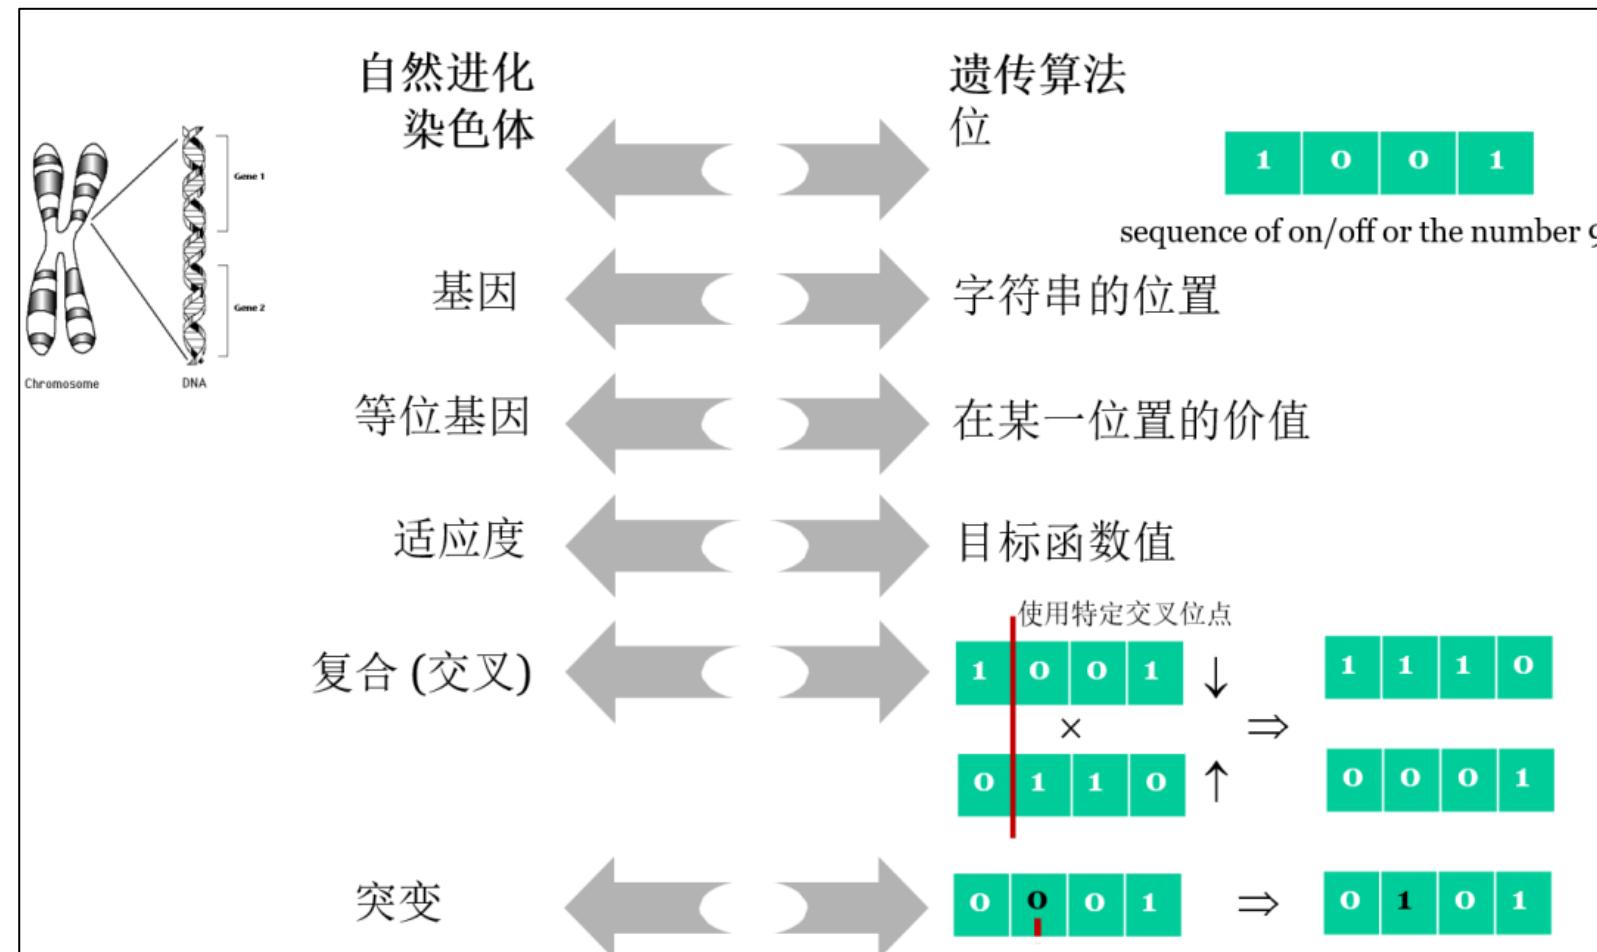
问题的启发式信息，将问题的状态转换成对问题的解决程度



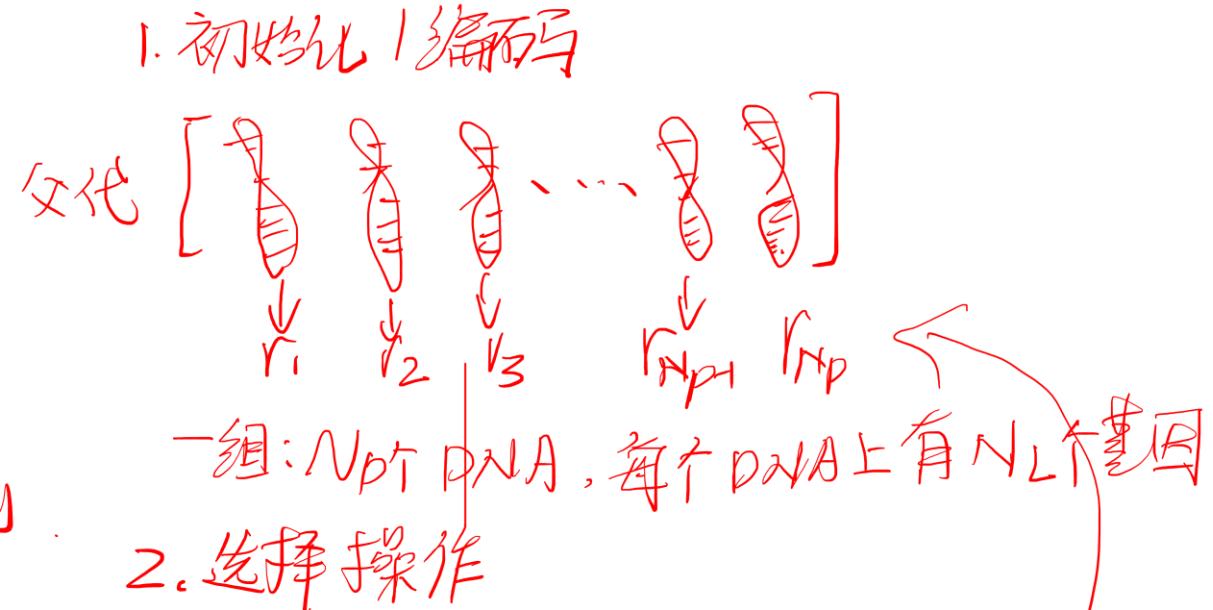
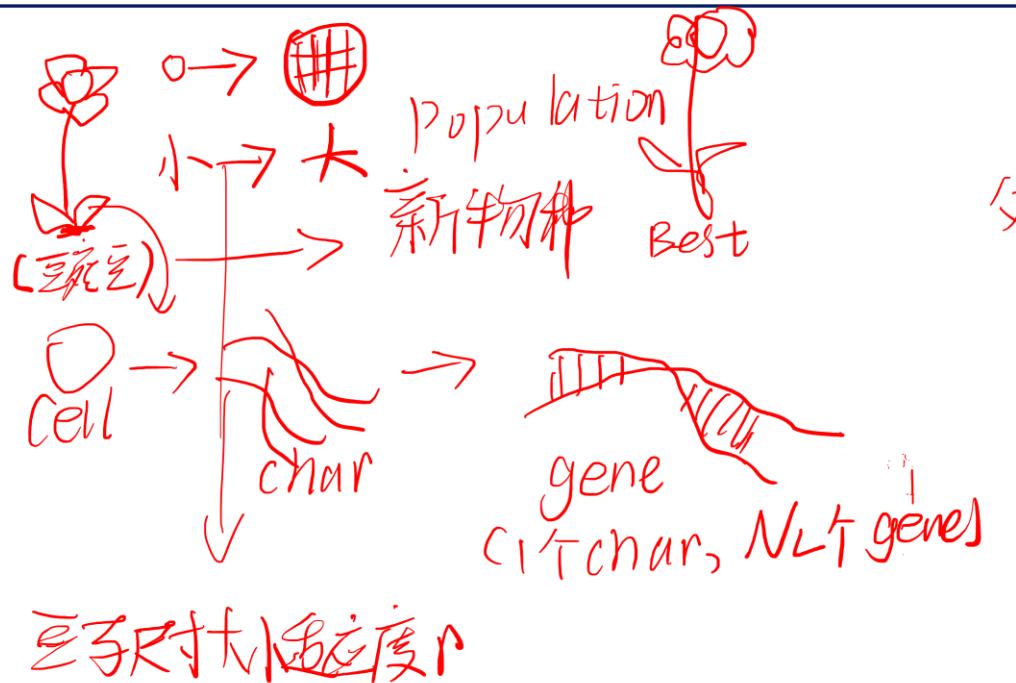
From Biology's Theory of Genes and Evolution to Genetic Algorithms



自然	GA
环境	优化问题
个体在环境中生存	可行的解决方案
个体对周围环境的适应程度	解的质量 (适应度函数)
生物体(物种)的种群	一组可行的解决方案
自然进化过程中的选择、重组和突变	随机运算操作
适应环境的种群进化	对一组可行解迭代地应用一组随机算子



How to breed a basketball-sized pea species ?



子代 [

$r:$ _____

占比概率?

3. 交叉操作



4. 变异操作



Introduction

Fundamental Elements

Chromosome coding methods

Fitness function design

**Three genetic operator operations
(selection-crossover-mutation)**

染色体编码方法

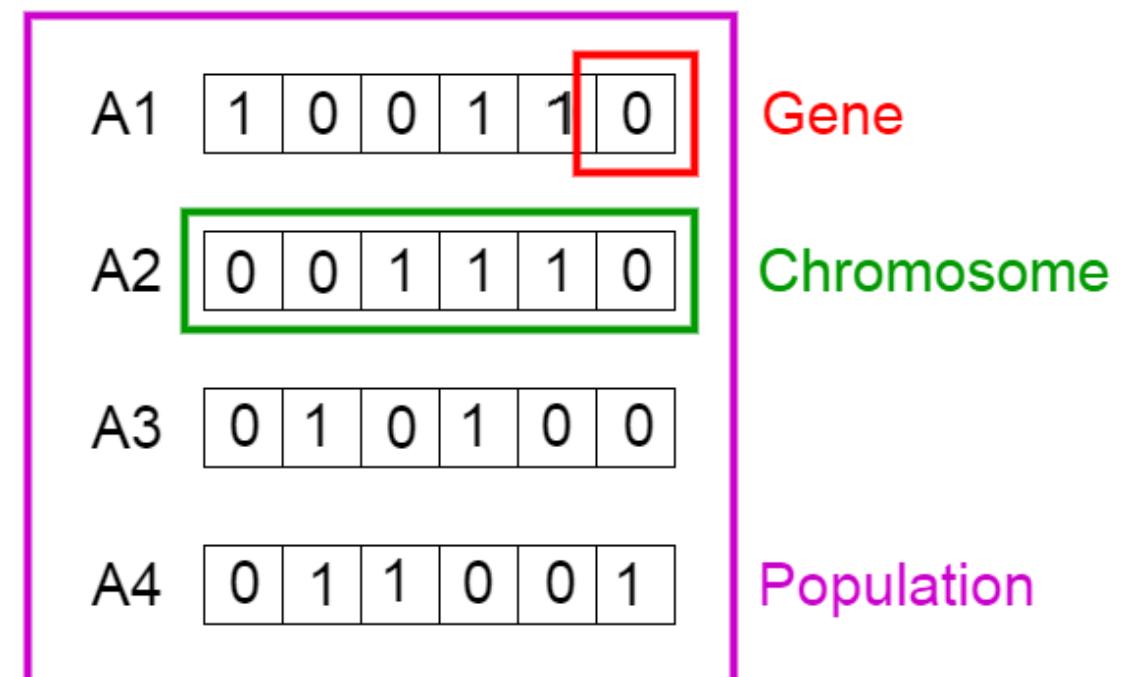
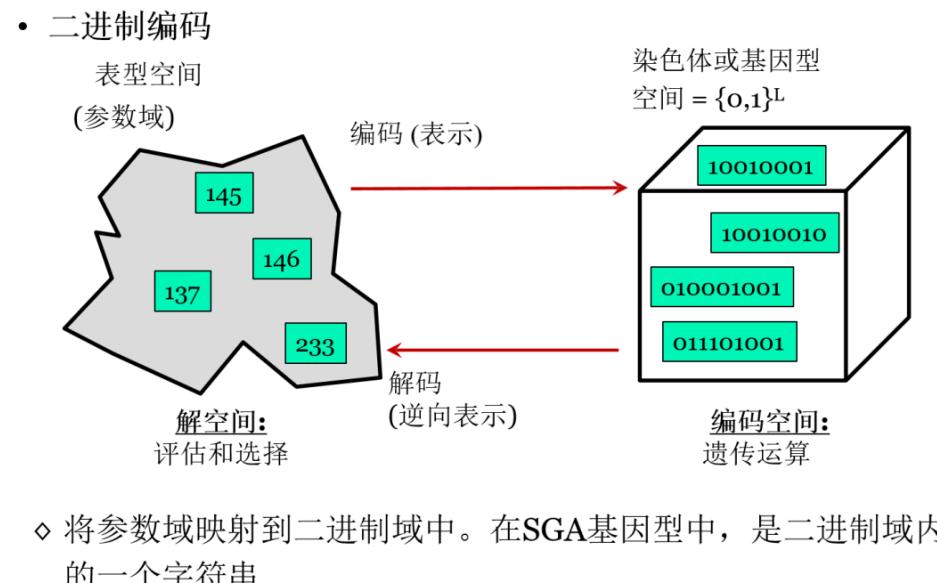
适应度函数设计

**三遗传算子操作
(选择-交叉-变异)**

Encode 参数编码

染色体编码方法指将问题的解空间映射到染色体上的过程.

通常采用二进制编码方法，将问题的解表示为一个二进制串.



Fitness Function 适应度函数设计

适应度函数(Fitness Function)

非常重要? 算法-评价个体优劣的标准, 算法演化中的驱动力
个体-被选择的概率, 自然选择的唯一依据

如何设计?

目标函数 (求解优化的问题)

↓ (映射)

适应度函数0

↓ (定标)

适应度函数

Deceptive Problem 欺骗问题

目标函数 (求解的优化问题)

↓ 映射

适应度函数 (f)

$$\hookrightarrow \text{Max } F_{\text{fit}}(f_{\text{true}}) = f_{\text{true}}$$

$$\text{Min } F_{\text{fit}}(f_{\text{true}}) = \frac{1}{f_{\text{true}}}$$

↓ 定标 (尺度变换)

why?

欺骗问题

(精英问题)

(a,b)

线性变换 $f' = af + b$

how 非线性变换 $f' = f^k$
 $f' = e^{-af}$

{ 前期: 个体精英 (个体适应值过高) \rightarrow 过早收敛 \rightarrow 局部最优解.

{ 后期: 群体精英 (平均适应值 \approx 最佳适应值) \rightarrow 萍藻发散 \rightarrow "无解."

方法: 改变原始适应值 的比例关系 提高个体之间(群体)的差异
(变换)

Fitness Scaling 尺度变换

推导 $f' = af + b$ } 原 \rightarrow 后 $f \rightarrow f'$ (适应度函数值域的某种映射变换)
尺度变换(坐标) ↗ rule 立标的后的适应度函数 f'

- a,b? 规则 { ① 平均值不变: $f'^{\text{avg}} = f^{\text{avg}}$, $C_{\text{mut}} = 1$ 下一代的期望 C_{py}
② 最大值倍数: $f'^{\max} = C_{\text{mut}} f^{\max}$, C_{mut} 复制数
 $(50 \sim 100 \rightarrow 1.2 \sim 2.0)$

$$\begin{cases} f' = af + b \\ f'^{\text{avg}} = f^{\text{avg}} \\ f'^{\max} = C_{\text{mut}} f^{\text{avg}} \end{cases} \Rightarrow \begin{cases} a = \frac{(C_{\text{mut}} - 1)f^{\text{avg}}}{f^{\max} - f^{\text{avg}}} \\ b = \frac{(f^{\max} - C_{\text{mut}}f^{\text{avg}})f^{\text{avg}}}{f^{\max} - f^{\text{avg}}} \end{cases} \quad \boxed{f' = af + b}$$

非线性变换: $f' = f^K$ (K , 与问题有关)

$f' = e^{-af}$ (a , 复制的强制性) $a \downarrow \rightarrow$ 具有 P_{\max} 个体
(为适应度).

Reproduction 选择

选择 (复制/遗传/繁殖)

从当前群体中按照一定概率选出优良个体使其有机会作为父代繁殖子代

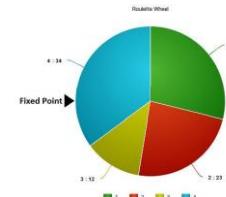
误区

- Best 最好 确定性优化方法 收敛 局部最优解
- Random 随机 完全随机方法 发散 滞缓 (不) 收敛

方法

基本方法：个体选择概率分配法（适应度比例方法 Monte Carlo）

其他方法：轮盘赌、锦标赛、精英选拔



设群体规模大小为 M , 个体 i 的适应度值为 f_i , 则这个个体被选择的概率为

$$p_{si} = \frac{f_i}{\sum_{i=1}^M f_i}$$

Crossover 交叉

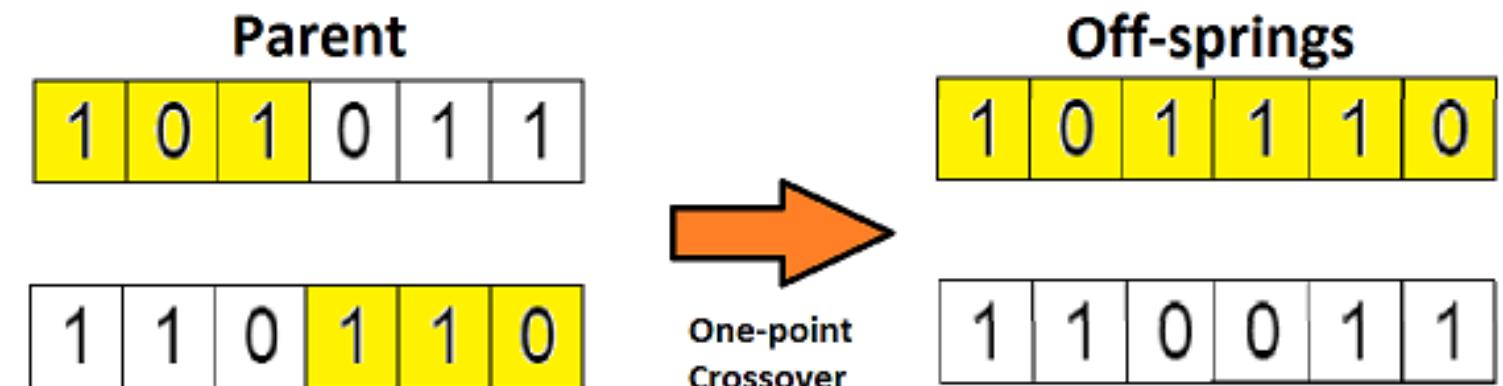
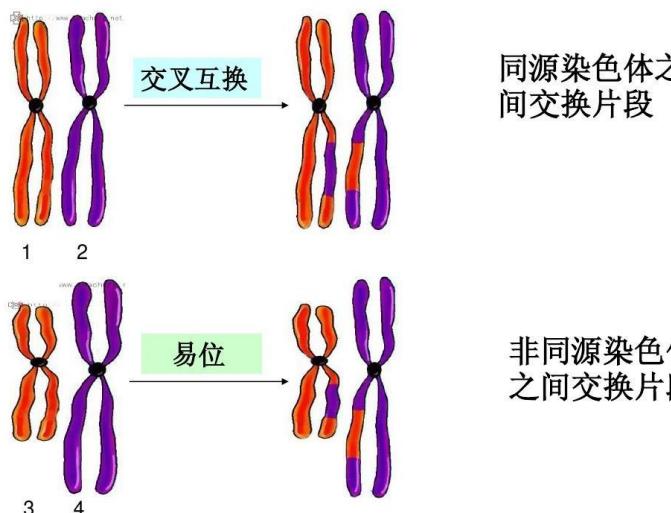
交叉~ (重组)

交叉算子~基因重组
父串→子串~父代→子代

交叉算子:

基本方法: 一点交叉SX、二点交叉TX、多点交叉MX

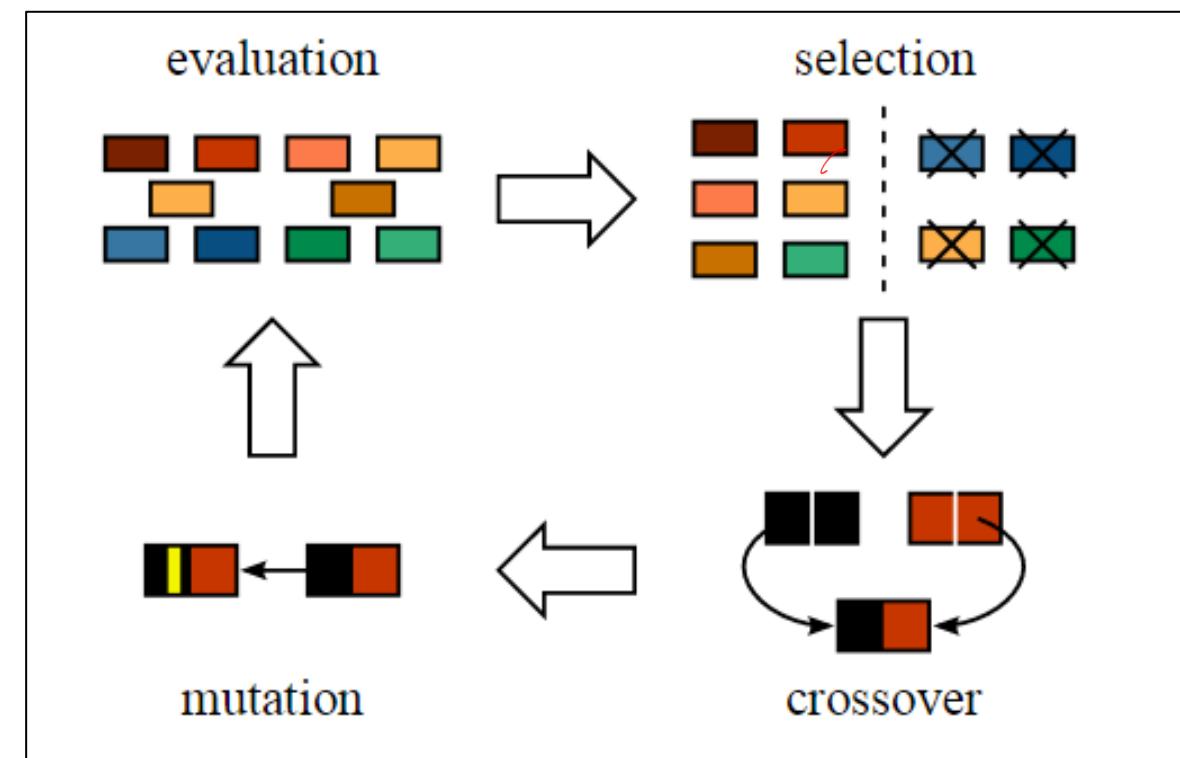
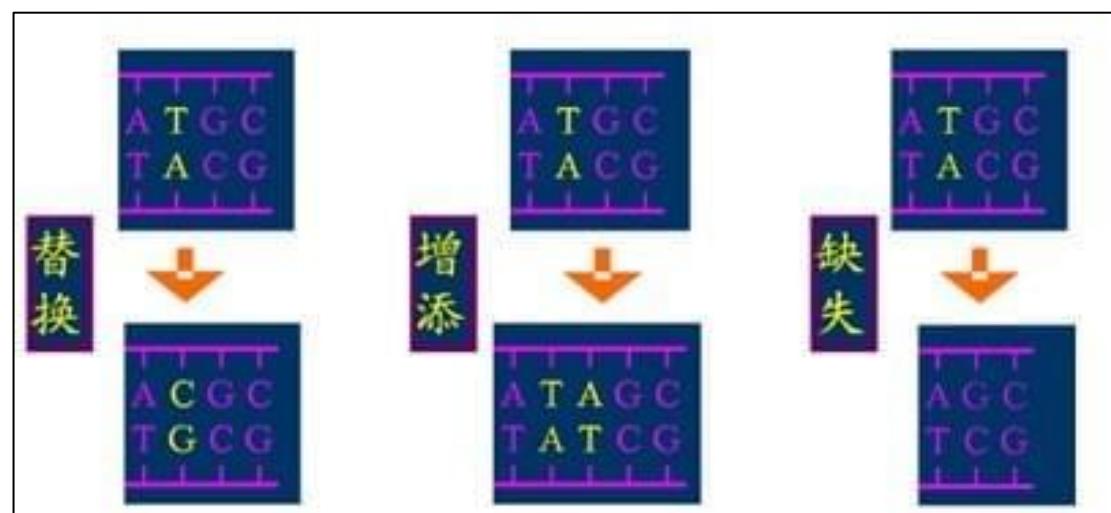
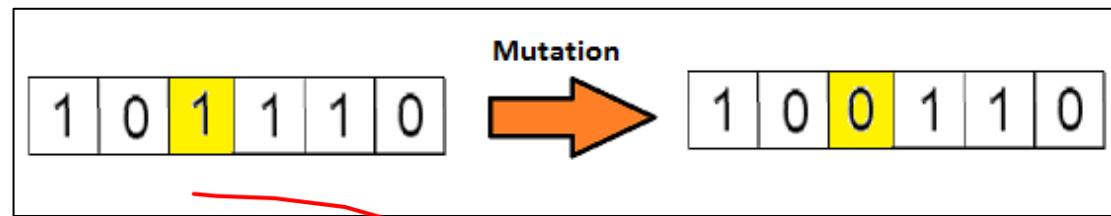
修正方法: 部分交叉PMX、顺序交叉OX、循环交叉CX



Mutation 变异

变异算子~基因突变

变异算子：位点、逆转、插入、互换、移动





算法-伪代码

综上所述,遗传算法步骤如下:

Step 1 使用随机方法或者其他方法,产生一个有 N 个染色体的初始群体 $pop(1), t:=1$; ① 初始群体用 $pop(1)$

Step 2 对群体 $pop(t)$ 中的每一个染色体 $pop_i(t)$,计算它的适应值

$$f_i = fitness(pop_i(t))$$

Step 3 若满足停止条件,则算法停止;否则,以概率

$$p_i = f_i / \sum_{j=1}^N f_j$$

② 每一个染色体 $pop_i(t)$
去

从 $pop(t)$ 中随机选择一些染色体构成一个新种群

$$newpop(t+1) = \{pop_j(t) \mid j = 1, 2, \dots, N\}$$

Step 4 以概率 P_c 进行交叉产生一些新的染色体,得到一个新的群体

$$crosspop(t+1)$$

Step 5 以一个较小的概率 P_m 使染色体的一个基因发生变异,形成 $mutpop(t+1); t:=t+1$,成为一个新的群体 $pop(t)=mutpop(t+1)$; 返回 Step 2。



算法-流程图

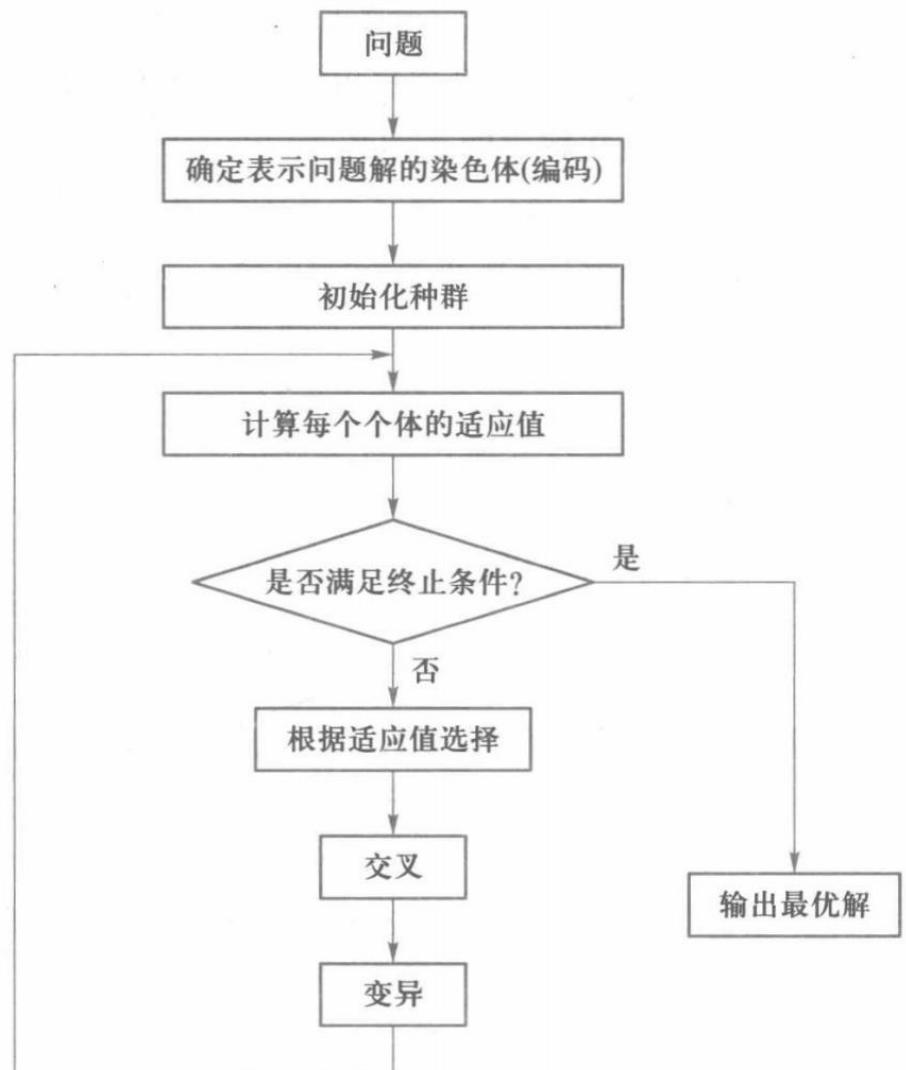


图 6.2 遗传算法的基本流程

Improvements

Improve: why? How?

Back to Biology

Basic Genetic Algorithms

Diploid Genetic Algorithms

Dual Population Genetic Algorithms

Adaptive Genetic Algorithms

回到生物学问题

基本遗传算法

双倍体遗传算法

双种群遗传算法

自适应遗传算法

Back to Biology

Simple Genetic Algorithm

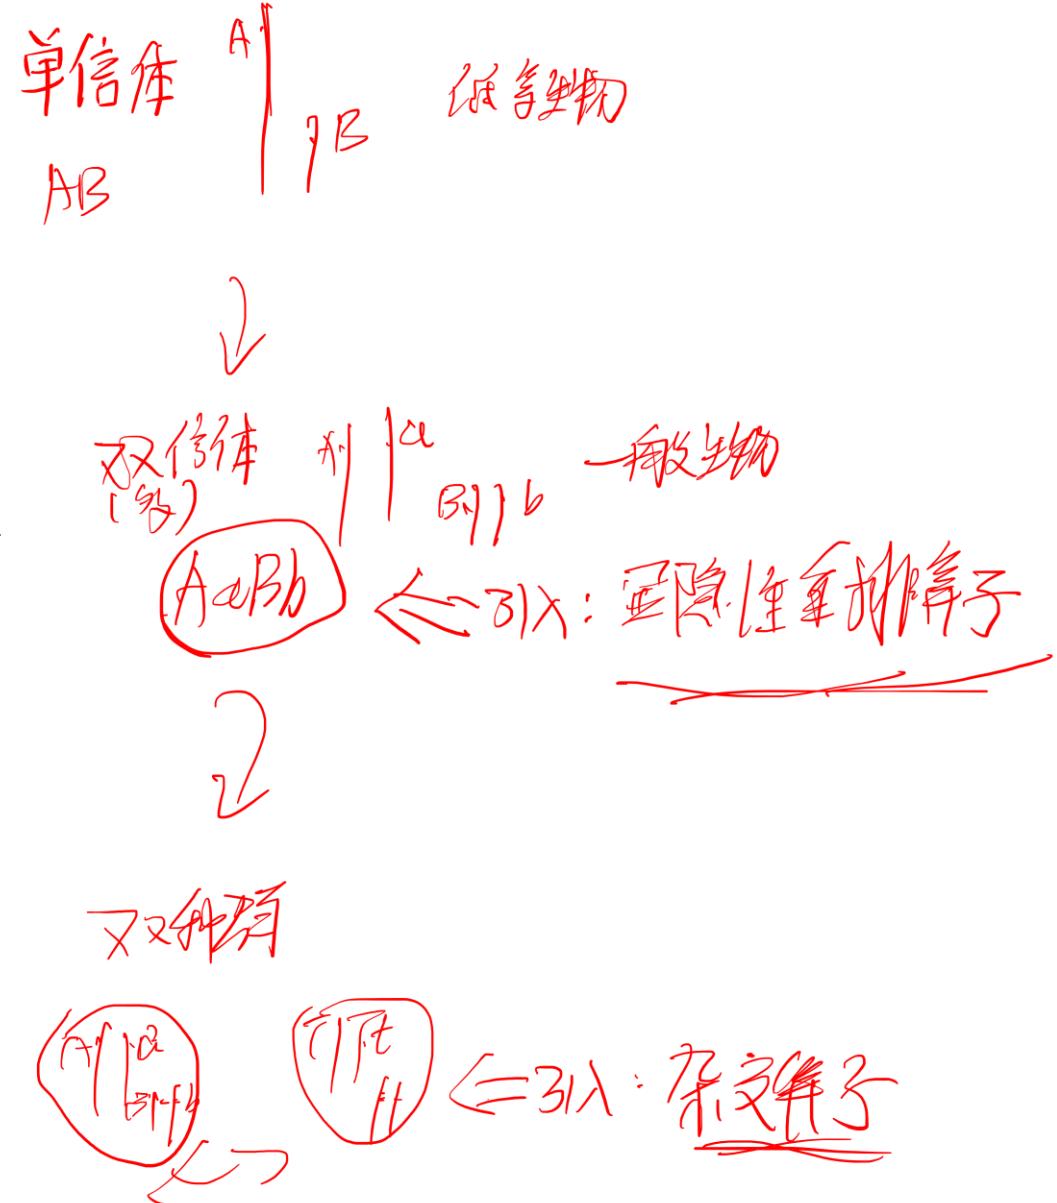
基本遗传算法(SGA)

Double Chromosomes Genetic Algorithm

双倍体遗传算法(DCGA)

Double Population Genetic Algorithm

双种群遗传算法(DPGA)



DCGA & DPGA

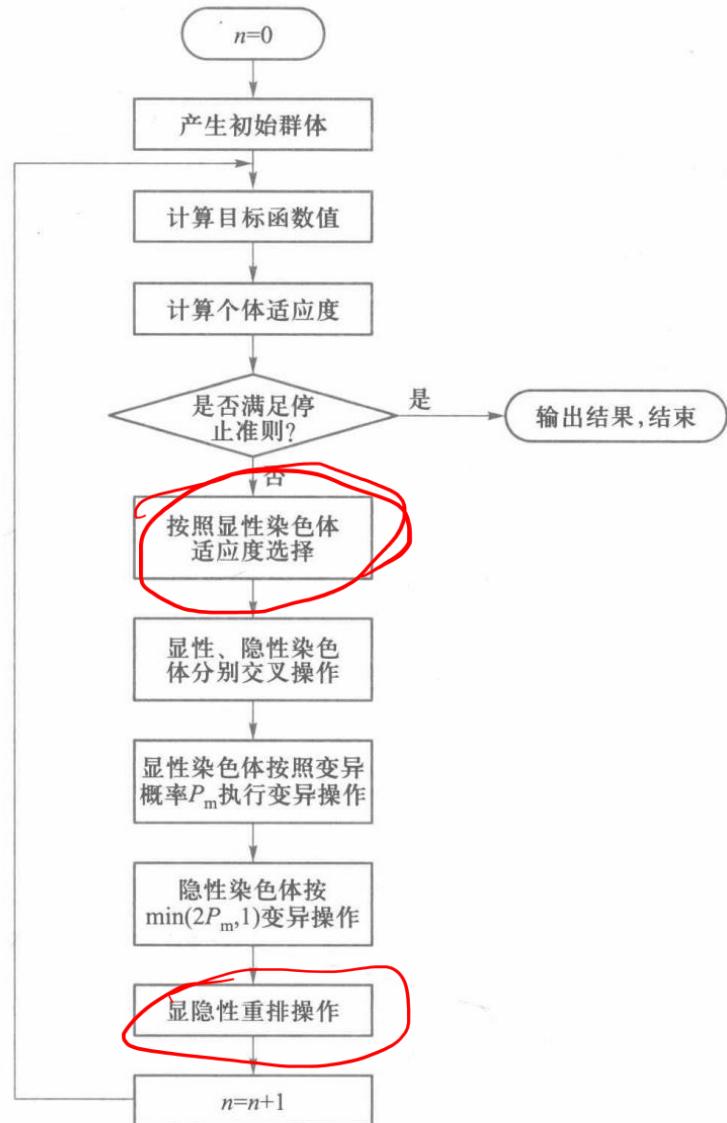


图 6.4 双倍体遗传算法程序流程

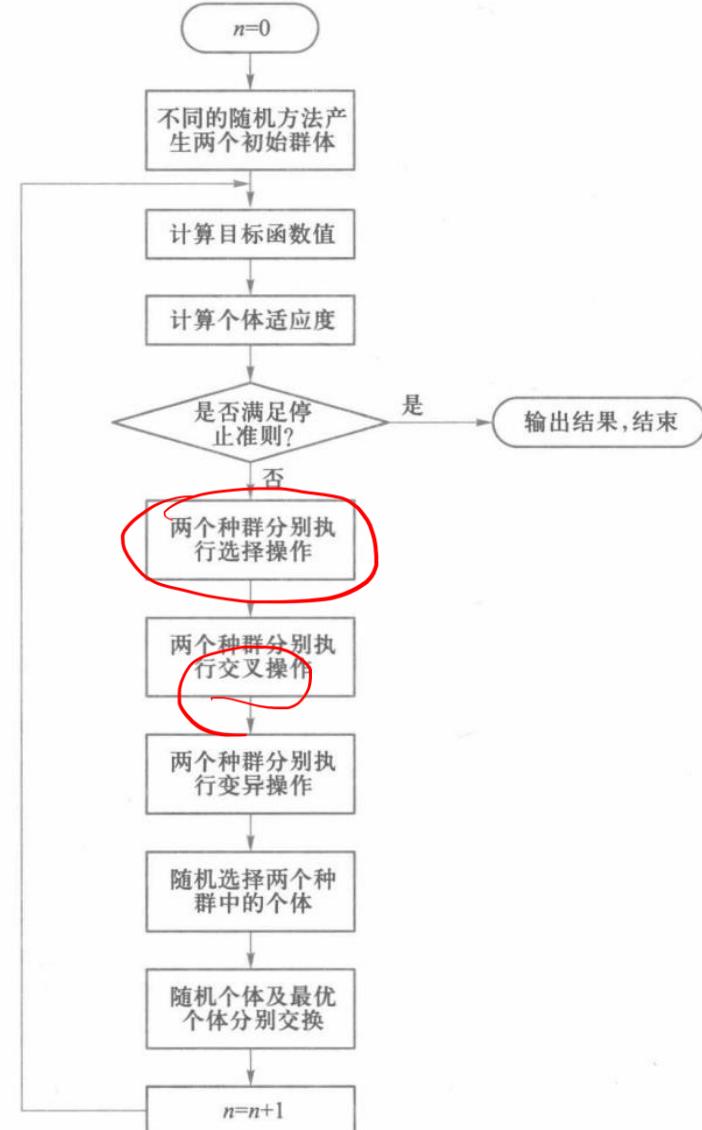


图 6.5 双种群遗传算法程序流程

P_c & P_m 问题

交叉概率c和变异概率m是影响遗传算法的行为和性能的关键参数，直接影响算法的收敛性。

交叉概率c (新个体产生的速度)

过大：破坏高适应度的个体结构（遗传模式）

过小：搜索变慢

变异概率m (个体新的结构)

过大：沦为纯粹的随机搜索算法

过小：不易产生新的个体结构

→ 难点：C和m针对不同优化问题，反复试验确定，难以找到适用于每个问题的最佳值

→ 解决：c和m随着适应度r变化而自动改变（自适应）

最佳 P_c & P_m

自适应：c和m随着适应度r变化而自动改变

群体适应度：

过早收敛：增加c和m，跳出局部最优解

发散滞缓：减少c和m，利于优良个体生存

个体适应度：

高于平均适应度：降低c和m，保护该解

低于平均适应度：增加c和m，淘汰该解

因此，自适应的c和m能够提供针对某个解的最佳c和m

自此，自适应遗传算法实现了保持群体多样性+保证遗传算法的收敛性

Adaptive Genetic Algorithms

Step1 编码/解码设计同基本遗传算法。

Step2 用初始种群产生的一些方法,产生 N (N 是偶数)个候选解,组成初始解集。

Step3 定义适应度函数为 $f = 1/ob$,计算适应度 f_i 。

Step4 按照轮盘赌规则选择 N 个个体,计算群体的平均适应度 f_{avg} 和最大适应度 f_{max} 。

Step5 将群体中的各个个体随机搭配成对,共组成 $N/2$ 对,对每一对个体,按照自适应公式计算自适应交叉概率 P_c ,以 P_c 为交叉概率进行交叉操作,即随机产生 $R(0,1)$,如果 $R < P_c$ 则对该对染色体进行交叉操作。

Step6 对于群体中的所有个体,共 N 个,按照自适应变异公式计算自适应变异概率 P_m ,以 P_m 为变异概率进行变异操作,即随机产生 $R(0,1)$,如果 $R < P_m$ 则对该染色体进行交叉操作。

Step7 计算由交叉和变异生成新个体的适应度,新个体与父代一起构成新群体。

Step8 判断是否达到预定的迭代次数,是则结束寻优过程,否则转 Step4。

Generation



优点：适用范围广，全局搜索能力强，并行性强，不需要求导，可处理非线性、非凸、非光滑等复杂问题。

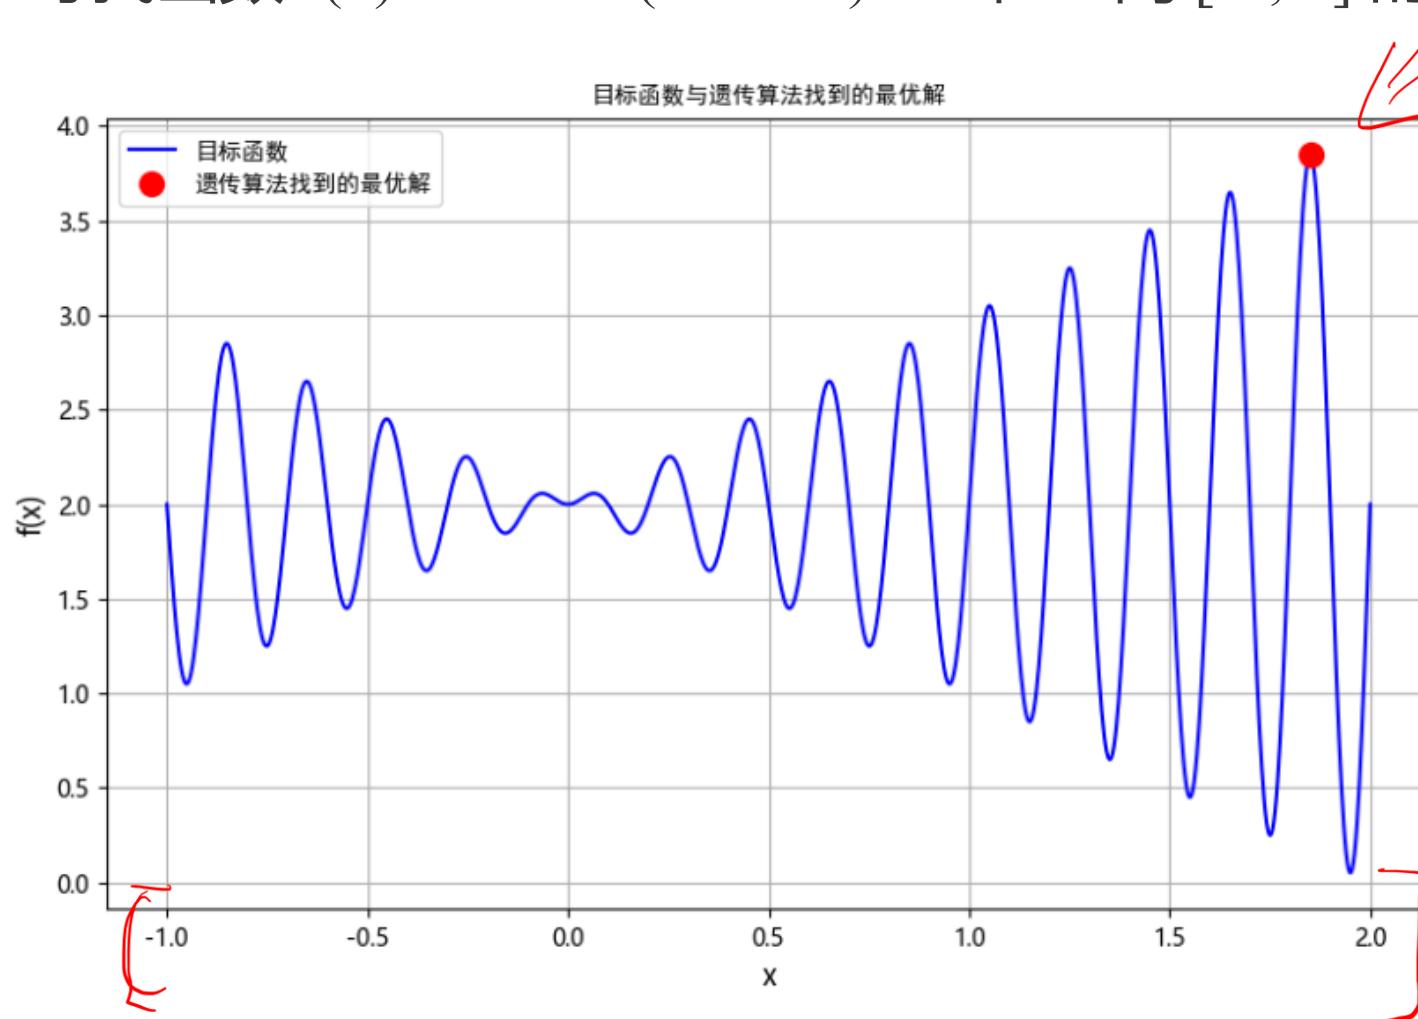
缺点：需要大量的计算资源，参数设置困难，可能会陷入局部最优解。

应用：各类优化问题

Applications

MATH: Function Optimal Solution

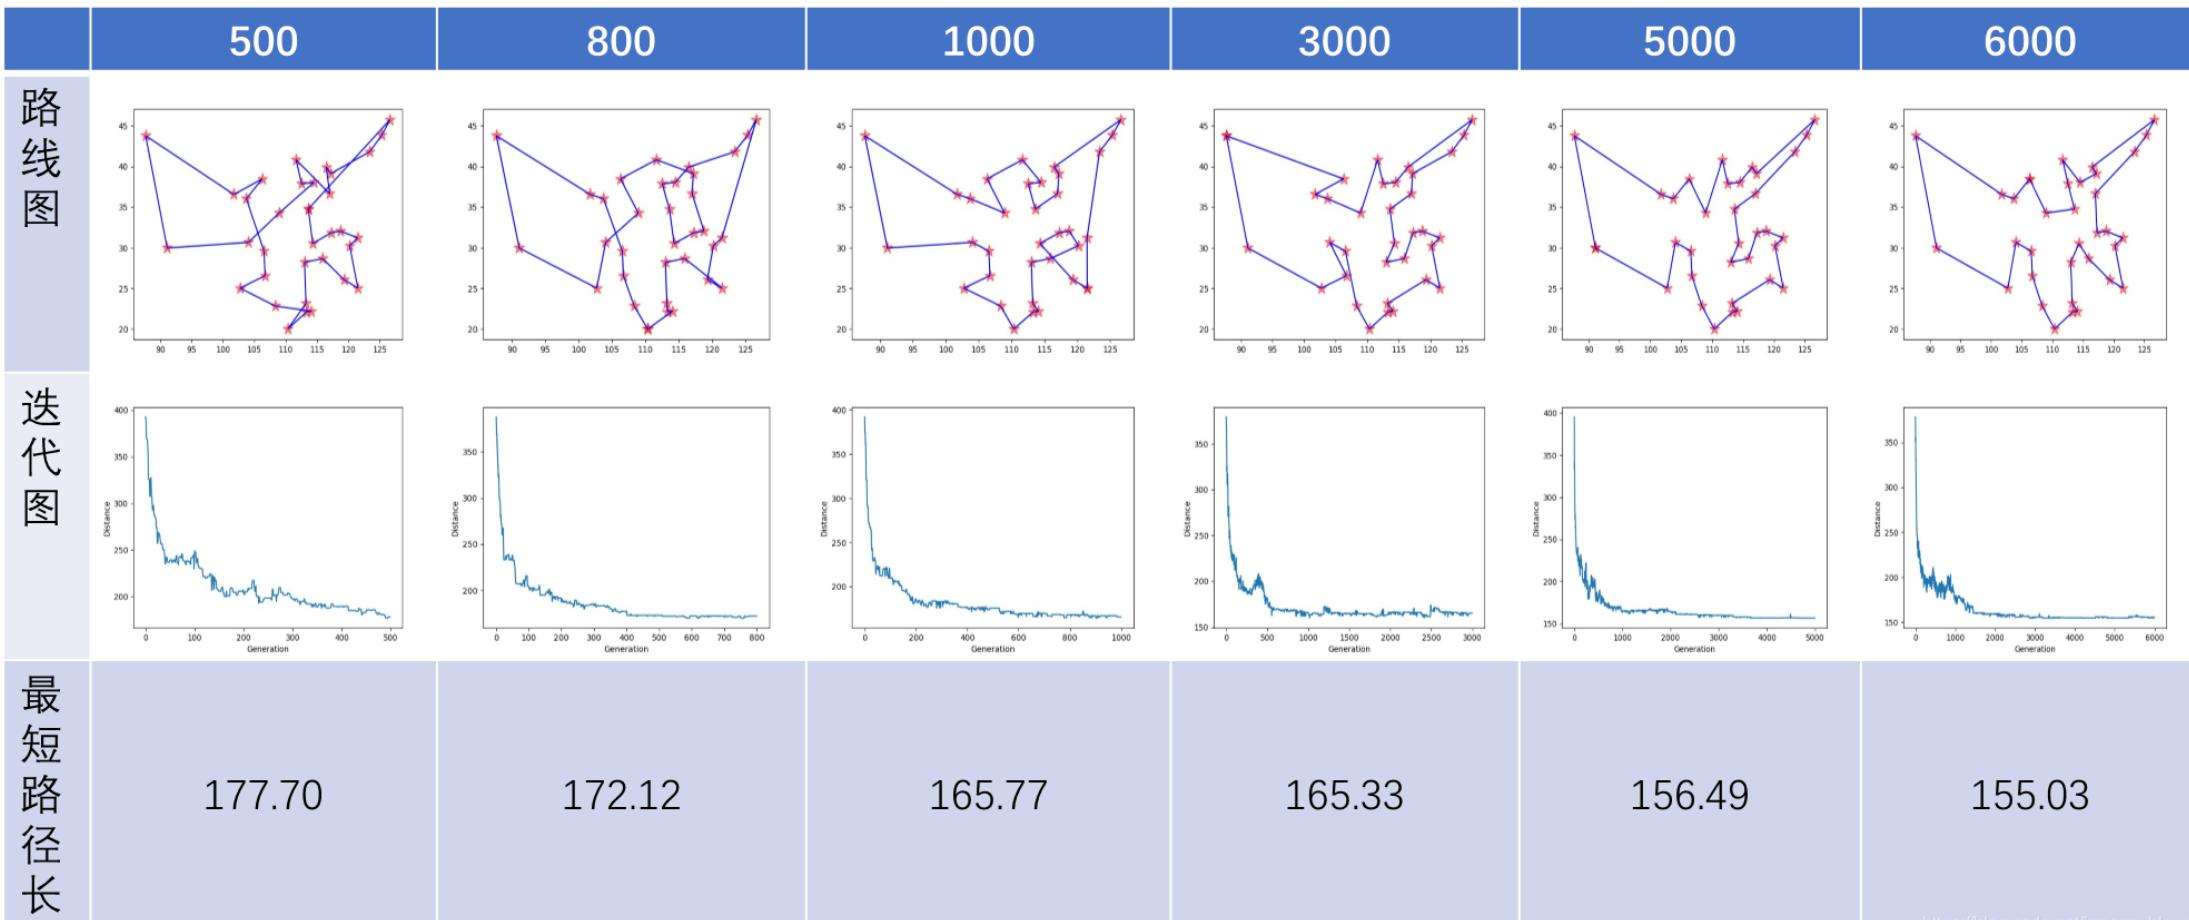
数学：寻找函数 $f(x) = x * \sin(10\pi * x) + 2$ 在区间 $[-1, 2]$ 的最大值



Algorithm: Travelling salesman problem, TSP

算法：组合优化问题，NP完全问题

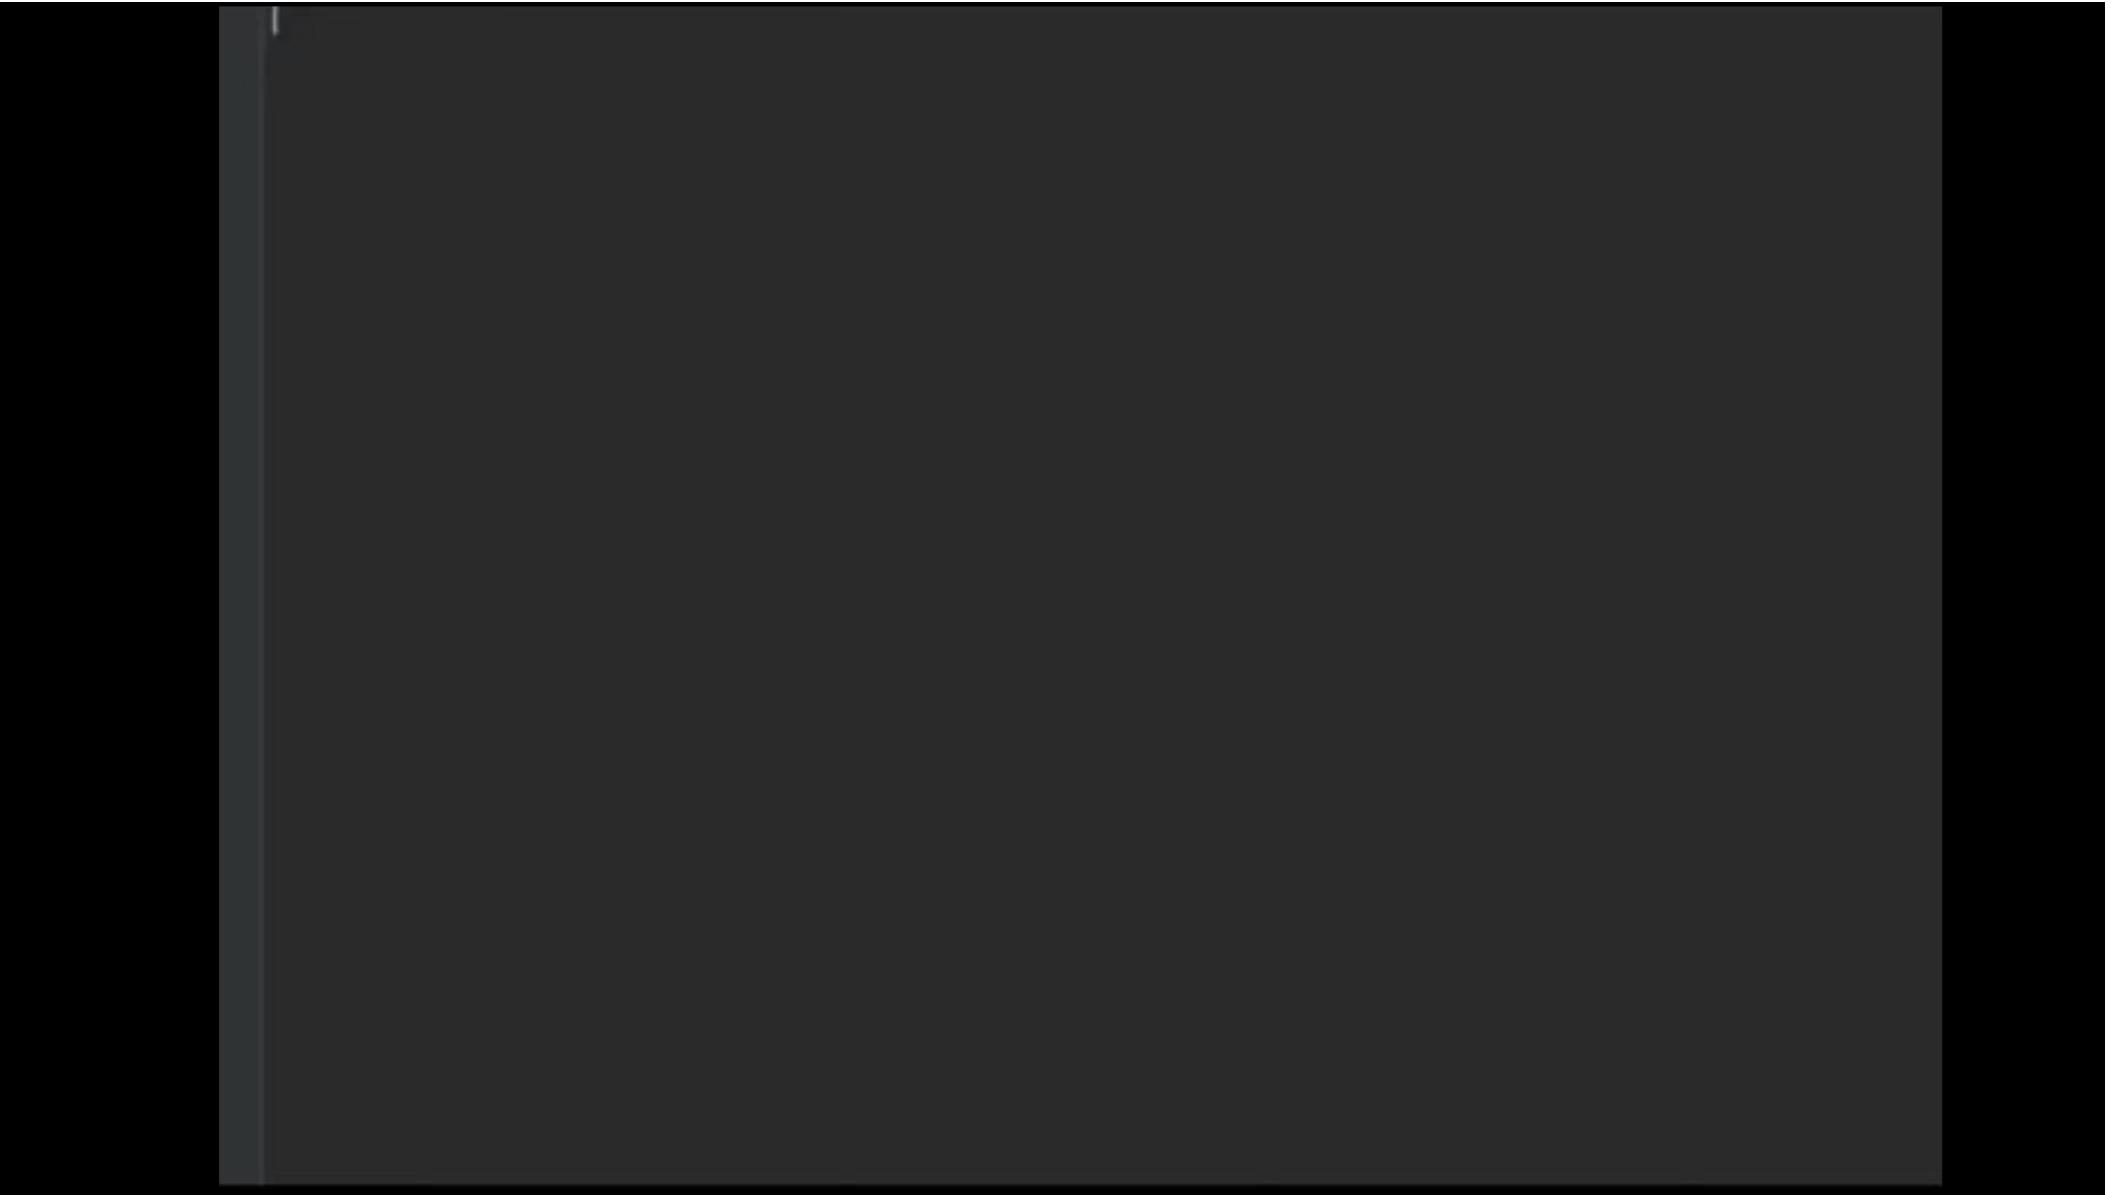
城市旅行商问题¹：设有n个城市和距离矩阵 $D=[d_{ij}]$ ，其中 d_{ij} 表示城市i到城市j的距离， $i, j=1, 2 \dots n$ ，则问题是要找出遍访每个城市恰好一次的一条回路并使其路径长度为最短。



¹https://blog.csdn.net/breeze_blow/article/details/102992997

Travelling salesman problem, TSP

DEMO¹



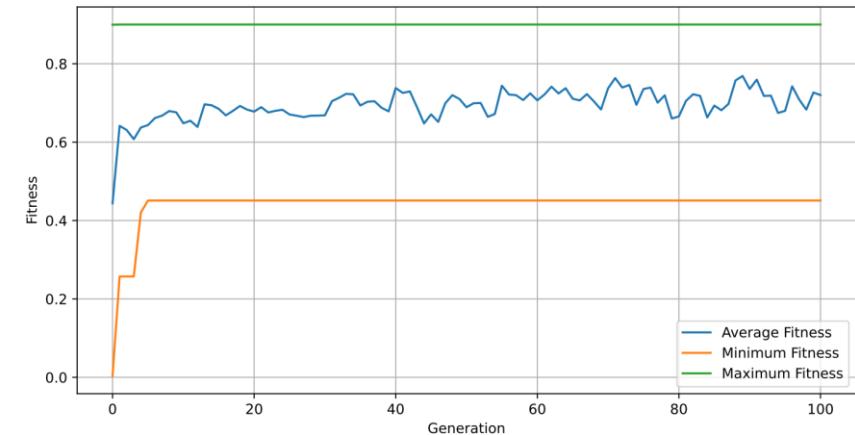
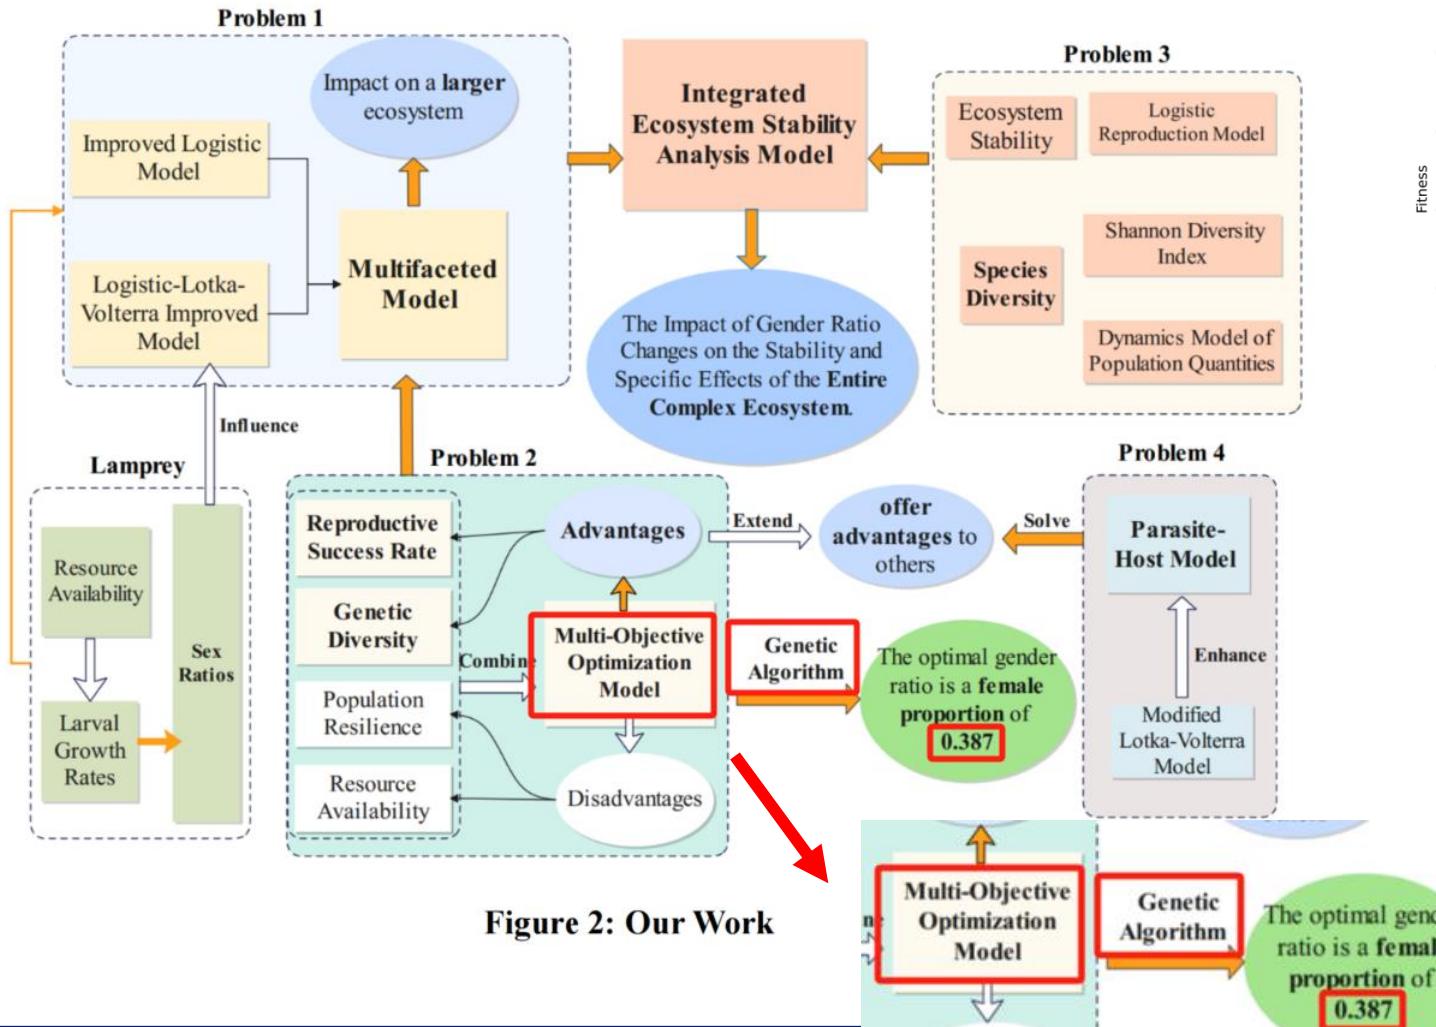
¹Completed by Xiong Gao

Modeling : Mathematical Modeling for Problem Solving

生物学, 种群繁衍 (短期) 物种进化 (长期)

探究动物能够根据资源可用性改变性比例的优缺点, 以及对生态系统的影响. (2024MCM-A)

Exploring the Eco Impacts of Lamprey Gender Variability through an Enhanced Lotka-Volterra Model¹



2024
Mathematical Contest In Modeling®
Certificate of Achievement

Be It Known That The Team Of

Yuhong Wang
Zixing Wang
Zhi Wang

With Faculty Advisor
Ying Lv

of
Southwest University
Was Designated As
Finalist

Finalist 特等奖提名 (1%)

Tail Call
Paul Kehle, Interim Executive Director

COPD
Steven B. Horton, Contest Director

With support from

公众号 · 行者小王

¹Completed by Yuhong Wang (& Zhi Wang & Zixing Wang)

Summary



Genetic Algorithm¹ is a search algorithm for optimizationon based on Mendel's laws and Darwin's theory ?+(Watson-Crick).

It performs selection(选择) , crossover (遗传) and mutation (变异) operations in the population (种群) by simulating the process of biological evolution (进化) , so as to optimize the objective function (目标函数) step by step (演化) .

Prospects: **Multimodal Data Processing; Deep Learning**

Insight: the **Intersection** of Biology, Mathematics and Algorithms

¹John H. Holland



Thank You for Listening !

Email:wyhstar@email.swu.edu.cn

References

- Forrest, Stephanie. "Genetic algorithms." ACM computing surveys (CSUR) 28.1 (1996): 77-80.
- Lee, Shane. "Genetic algorithms." Orthogonal arrays (2002).
- Murthy, C. A., and MACHINE INTELLIGENCE UNIT. "Genetic Algorithms: Basic principles and applications." 2012 2nd National Conference on Computational Intelligence and Signal Processing (CISP). IEEE, 2012.
- Forrest, Stephanie. "Genetic algorithms: principles of natural selection applied to computation." Science 261.5123 (1993): 872-878.
- Ye, Zhisheng, Zhizhong Li, and Min Xie. "Some improvements on adaptive genetic algorithms for reliability-related applications." Reliability Engineering & System Safety 95.2 (2010): 120-126.
- Tang, Kit-Sang, et al. "Genetic algorithms and their applications." IEEE signal processing magazine 13.6 (1996): 22-37.
- Evolutionary Algorithms and Neural Networks, 2019, Volume 780 ISBN : 978-3-319-93024-4